

Alumno : Mandarin Rosales Angel Eduardo

1. ¿Cuál de las siguientes declaraciones sobre el aprendizaje es incorrecta?

- 1 El aprendizaje supervisado utiliza tanto datos de entrada como datos de aprendizaje dado un resultado, pero el aprendizaje no supervisado se utiliza en forma de aprendizaje utilizando sólo datos de entrada sin datos de aprendizaje.
- 2 Se puede decir que el aprendizaje no supervisado es un método de aprendizaje que informa del problema pero no dice la respuesta.
- 3 Como algoritmo de aprendizaje no supervisado, el análisis de agrupación jerárquica y la agrupación de K-means se pueden utilizar para la agrupación.
- 4 La agrupación de K-means tiene la ventaja de ser fácil de determinar el número inicial de agrupaciones y fácil de interpretar los resultados.

2. ¿Cuál de las siguientes declaraciones sobre la agrupación es incorrecta?

- 1 La técnica de agrupamiento más utilizada es K-Means.
- 2 La agrupación jerárquica se decide después de la agrupación sin determinar el número de grupos.
- 3 El algoritmo de la agrupación jerárquica tiene K-Medoides.
- 4 La agrupación es una técnica que asigna y analiza grupos basados en la similitud o disimilitud entre cada entidad.

3. El algoritmo EM pertenece a los algoritmos codiciosos. Explique la razón.

El algoritmo Expectation-Maximization (EM) puede considerarse codicioso en el sentido de que en cada iteración, realiza pasos que aumentan la verosimilitud de los datos. En cada fase (E y M), el algoritmo optimiza localmente la función objetivo sin garantizar encontrar el óptimo global, sino un máximo local.

4. Escriba tres o más ejemplos de algoritmo de agrupación. (por ejemplo, análisis de datos)

Agrupamiento jerárquico, K-means y DBSCAN

5. Explique los dos métodos para elegir el número óptimo de conglomerados cuando se utiliza k-means. Describa cómo encontrar el número óptimo de conglomerados utilizando los dos métodos.

el metodo mas utilizado para determinar el numero óptimo de clusters es el metodo del codo. El cual consiste en entrenar el modelo con diferentes valores de k y calculando que tan similares son los datos dentro de cada conglomerado mediante la suma de los cuadrados. posteriormente, se construye una grafica en la que se observa como cambia esta medida en funcion de k. El punto donde la grafica presente una inflexion se considera el valor optimo de k

- Agrupe y visualice los datos de muestra del código siguiente utilizando los algoritmos KMeans, Agrupamiento Aglomerativo y DBSCAN. Sin embargo, para K-Means y los agrupamientos aglomerativos, establecer el número de grupos a 3.


In [130...

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.datasets import make_blobs, make_moons
from sklearn.cluster import KMeans, DBSCAN, AgglomerativeClustering
```

In [131...

```
X, label = make_blobs(n_samples=300, n_features=2, centers=3, cluster_std=5, random_state=1)
plt.scatter(X[:,0], X[:,1], c=label, alpha=0.7)
plt.title('Dataset #1 Original')
plt.show()
```



In [132...

```
## Generamos el modelo K-means

KMeans = KMeans(n_clusters=3).fit(X)

#asignamos un determinado cluster
KMeans.labels_

print('Posicion de los centroides: \n', KMeans.cluster_centers_) # arreglo de numpy

plt.figure(figsize=(6,5))


## Creamos la grafica
for cluster in range(KMeans.n_clusters):
    plt.scatter(X[:,0], X[:,1], c=KMeans.labels_, alpha=0.2)

    plt.scatter(
        KMeans.cluster_centers_[cluster][0],
```

```
KMeans.cluster_centers_[cluster][1],
marker='P',s=200,color='black')

plt.title('K-means')
plt.show()
```

Posicion de los centroides:
[[3.49795097 -7.41151301]
[7.13828218 0.94946968]
[-6.89494507 0.58076306]]




```
In [ ]: #epsilon - radio del circulo de vecindad alrededor de un punto
# min_samples - minimo de puntos dentro del circulo
cluster = DBSCAN(eps=2,min_samples=5).fit_predict(X)

# Crear el diagrama de dispersión
plt.figure(figsize=(6, 5))

plt.scatter(X[:, 0], X[:, 1],
            c=cluster, s=50, alpha=0.7)

plt.title("DBSCAN")
plt.show()
```



```
In [140... ## Agrupamiento jerarquico
jerarquico = AgglomerativeClustering(n_clusters=3).fit(X)
jerarquico.labels_

## Creamos el diagrama de dispersión
plt.figure(figsize=(6,5))

plt.scatter(X[:, 0], X[:, 1],
            c=jerarquico.labels_, cmap='viridis', s=50,alpha=0.7)

plt.title('Agrupamiento jerarquico')
plt.show()
```

Agrupamiento jerárquico

